

기계학습 기말고사

CardioCare: 심장병 예측 머신러닝 시스템

컴퓨터공학과 202221019 이은빈

1. 문제 정의와 사용 목적

본 프로젝트는 임상 데이터를 활용하여 심장병 발병 가능성을 예측하는 머신러닝 시스템 CardioCare를 구축한다. CardioCare는 심장 전문의의 의사결정을 보조(inform)하는 도구이며, 절대 단독으로 진단을 결정(decide)하지 않는다. 즉, 모델의 예측 결과는 전문의가 참고하는 정보 중 하나일 뿐이며, 최종 판단은 반드시 의료 전문가가 내려야 한다. UCI Heart Disease 데이터셋(Cleveland 포함 통합본, 303행)을 사용하며, 타겟은 이진 분류(0=정상, 1=심장병)로 정의한다.

2. EDA 핵심 결과

1) 데이터셋 기본 정보


- 전체 데이터: 303행, 14열 (타겟 포함)
- 결측값: ca 4개(1.32%), thal 2개(0.66%) 존재
- 중복값: 없음

2) 클래스 분포


- 정상(0): 164개 (54.1%)
- 심장병(1): 139개 (45.9%)
- 거의 균형잡힌 데이터로 별도 오버샘플링 불필요
- 평가 지표로 Balanced Accuracy 사용

3) 이상치 분석 (Boxplot + IQR)

- chol(콜레스테롤): 상위 이상치 다수 존재
- trestbps(안정시 혈압): 상위 이상치 존재
- oldpeak: 오른쪽으로 치우친 분포
- 이상치는 임상적으로 가능한 값이므로 제거하지 않고 유지



클래스 분포 그래프



박스플롯

3. EDA 결과에 근거한 전처리 결정

1) 결측값 처리

- 연속형 특성(ca, thal): 중앙값(median) 대체
→ 이상치에 강건한 중앙값을 선택
- 범주형 특성: 최빈값(most_frequent) 대체

2) 스케일링

- 연속형 특성에 StandardScaler 적용
- SVM, Logistic Regression 등 거리 기반 모델에 필수

3) 데이터 누수 방지

- 스케일러, 임퓨터 등 모든 변환기는 반드시 학습 데이터(train fold)에만 fit 수행
- sklearn.pipeline.Pipeline으로 구현하여 새 데이터에도 동일하게 재적용 가능

4) 특성 구분

- 연속형(5개): age, trestbps, chol, thalach, oldpeak
- 범주형(8개): sex, cp, fbs, restecg, exang, slope, ca, thal

4. MLflow 실험 기반 모델 비교 및 최종 선택

1) 데이터 분할

- 학습: 80% (242개), 테스트: 20% (61개)
- stratify=y로 클래스 비율 유지
- RANDOM_STATE = 42 고정

2) 모델 비교표

모델	Balanced Acc	F1	Recall	CV
Logistic Regression	0.873	0.867	0.929	-
SVC	0.823	0.814	0.857	-
Random Forest	0.919	0.912	0.929	최고

3) 최종 모델: Random Forest (GridSearchCV 하이퍼파라미터 튜닝)

- 선택 이유 : Random Forest가 Balanced Accuracy(0.919)와 F1(0.912) 모두 가장 높은 성능을 보였다. 특히 심장병 예측에서 False Negative (실제 심장병 환자를 정상으로 예측)는 치명적 결과를 초래할 수 있으므로 Recall(0.929)이 높은 모델을 선택하는 것이 임상적으로 중요하다. Random Forest는 세 지표 모두에서 우수한 성능을 보였으며, 5-fold 교차 검증에서도 가장 안정적인 결과를 나타냈다.

5. 테스트와 패키징

1) 단위 테스트 (tests/test_pipeline.py) : `python -m unittest` 으로 4개 테스트 모두 통과

- ◆ 테스트 1: 예측 결과 shape 일치 확인
 - 입력 303행에 대해 예측 결과도 303개인지 검증
 - 이유: 배치 추론 시 입출력 크기 불일치 방지
- ◆ 테스트 2: 예측 확률 범위 검증
 - 모든 확률값이 [0, 1] 범위이고 행마다 합이 1인지 검증
 - 이유: 확률값 이상 시 모델 신뢰성 저하 방지
- ◆ 테스트 3: 입력값 범위 검증
 - chol [0, 600], age [0, 120], trestbps [0, 300] 범위 검증
 - 이유: 임상적으로 불가능한 입력값 조기 차단
- ◆ 테스트 4: 결정론적 출력 확인
 - 동일 입력에 대해 항상 동일 출력 보장
 - 이유: 재현성 확보 및 디버깅 용이성

2) Docker 패키징 (Dockerfile)

- `python:3.11-slim` 베이스 이미지 사용
- `requirements.txt` 기반 의존성 설치
- 학습된 모델(`best_model.pkl`) 포함
- 빌드: `docker build -t cardiocare:1.0 .`
- 실행: `docker run cardiocare:1.0`

3) 피처 스토어 및 모델 레지스트리

- 피처 스토어 후보: chol (콜레스테롤)
 - 여러 심장 관련 모델에서 공통으로 사용되는 핵심 특성
- 모델 레지스트리 메타데이터: Balanced Accuracy, 학습 날짜, 데이터 버전, RANDOM_STATE
 - 모델 버전 관리 및 롤백 시 필요한 정보

6. 드리프트 결과 및 재학습 계획

1) 드리프트 시뮬레이션

- chol 평균 +80, 표준편차 +50 인위적 이동
- trestbps 평균 +30, 표준편차 +15 인위적 이동

2) KS 검정 결과 ($p < 0.05$ = 드리프트 감지)

- age: $p=0.8124$ 정상
- trestbps: $p=0.0000$ 드리프트 감지!
- chol: $p=0.0000$ 드리프트 감지!
- thalach: $p=0.9517$ 정상
- oldpeak: $p=0.2218$ 정상

3) 성능 변화


- 원본 테스트셋 Balanced Accuracy: 0.9188
- 드리프트 테스트셋 Balanced Accuracy: 0.8885
- 성능 하락: 0.0303 (3.3% 하락)

4) 재학습 전략

- 드리프트 감지 시 즉시 알림 발송
- 새 데이터 수집 후 전문의 레이블링 (Human-in-the-loop)
- 전체 파이프라인 재학습 (스케일러, 임퓨터 포함)
- A/B 테스트로 신규 모델 검증 후 배포

5) 폭주하는 피드백 루프 위험성

- 모델 예측을 그대로 레이블로 사용하면 편향이 증폭됨
- 반드시 의료 전문가가 레이블을 검토하고 승인해야 함
- Human-in-the-loop 개입 지점 :
 - (1) 새 데이터 레이블링 시
 - (2) 재학습 모델 배포 승인 시
 - (3) 드리프트 임계값 조정 시



시계열 성능 변화 그래프

7. 서빙 방식 결정

1) 서빙 선택지 : Model-as-a-Service vs On-Device

2) 선택 : Model-as-a-Service (MaaS)

3) 이유:

(1) 지연 시간

- 심장병 예측은 실시간 응답이 필요하지 않음
- 전문의가 진료 중 조회하는 방식이므로 수백 초(ms)의 네트워크 지연은 허용 가능

(2) 개인정보 (PHI, Protected Health Information)

- 환자 데이터는 병원 내부 서버에서만 처리
- 외부 클라우드 전송 시 암호화 필수
- On-Device보다 중앙 서버에서 접근 제어가 용이

(3) 업데이트 주기

- 드리프트 감지 시 즉시 서버 모델 교체 가능
- On-Device는 모든 기기에 개별 업데이트 필요
→ 버전 불일치 위험 존재

4) 결론

병원 내부 서버에 배포하는 Model-as-a-Service 방식이 보안, 관리, 업데이트 용이성 측면에서 적합하다. 단, 환자 데이터는 병원 네트워크 내에서만 처리하여 PHI 보호 규정을 준수해야 한다.

8. 한계, 윤리적 고려사항, 추가 개선 계획

1) 한계

- 데이터 크기: 303행으로 매우 작아 일반화 성능 제한
- 데이터 편향: Cleveland 병원 데이터 중심으로 다양한 인종/지역 환자에 대한 일반화 불확실
- 특성 부족: 흡연, 가족력 등 중요한 임상 정보 미포함
- 시계열 데이터 없음: 환자의 시간에 따른 변화 반영 불가

2) 윤리적 고려사항

- CardioCare는 심장 전문의의 의사결정을 보조하는 도구이며, 절대 단독으로 진단을 결정하지 않음
- False Negative(실제 환자를 정상으로 예측) 발생 시 치료 지연으로 생명에 위협이 될 수 있음
- 모델 예측에 대한 설명 가능성(Explainability) 부족
→ 의사가 왜 이런 예측이 나왔는지 이해하기 어려움
- 특정 연령, 성별, 인종 그룹에 대한 편향 가능성 존재
→ 정기적인 공정성(Fairness) 검사 필요

3) 1주가 더 주어진다면

- 조금 더 공부를 한 뒤 과제 실행
- SHAP을 활용한 모델 설명 가능성 추가
- 더 많은 데이터 수집 및 외부 검증 데이터셋 적용
- FastAPI로 REST API 서버 구축
- 성별/연령별 공정성 지표 측정 및 보고

- 실제 MLflow Registry로 모델 버전 관리 구현

부록: AI 도구 사용 고지

본 프로젝트에서 Claude(Anthropic)를 보일러플레이트 코드 작성과 디버깅에 활용하였다. 구체적으로는 sklearn Pipeline 구조 작성, MLflow 로깅 코드, unittest 테스트 메서드 구조, Dockerfile 작성, GitHub Actions ci.yml 설정에 활용하였다. 모든 코드의 내용과 동작 방식을 직접 이해하고 검토하였으며, 실험 설계, 모델 선택 근거, 보고서 작성은 직접 수행하였다.